

生产级工程实践

从“能跑”到“能用”— Week 3 总结 + V3 里程碑

第 3 周 · 第 12 节

讲师：黄佳（咖哥）

极客时间黄佳老师出品

灵魂拷问

多 Agent 工作流跑通了 但它能上生产吗？

生产级 = 功能 + 成本控制 + 安全 + 测试 + 可观测性

生产级系统的四个维度

维度 1: 成本控制 (CostGuard)

- 多 Agent 成本倍增效应 → 预算守卫 + 熔断器

维度 2: 安全防护 (Security)

- Prompt Injection + 数据泄露 → 三道防线

维度 3: 测试策略 (Testing)

- AI 输出不确定 → Unit + Integration + Eval 三层测试

维度 4: 日志与监控 (Observability)

- 多 Agent 交互复杂 → 结构化日志 + 运行报告

维度 1：成本控制

CostGuard — 预算守卫 + 熔断保护

多 Agent 管线成本估算



环节	角色	输入 tokens	输出 tokens	成本 (DeepSeek)
任务规划	Planner	~800	~500	¥0.0018
内容分析	Analyzer	~2000	~1500	¥0.005
质量审核	Reviewer	~2500	~800	¥0.0041
修订重跑	Analyzer	~2500	~1500	¥0.005
合计 (1 轮修订)	—	~7800	~4300	¥0.015

CostGuard — 预算守卫 + 预算熔断



cost_guard.py | python

```
class CostGuard:
    """追踪成本 + 预警 + 预算熔断"""

    def __init__(self, budget_yuan=1.0, alert_threshold=0.8):
        self.budget_yuan = budget_yuan
        self.alert_threshold = alert_threshold
        self.records = []
        self.total_cost_yuan = 0.0

    def record(self, node_name, usage, model=''):
        """记录一次 LLM 调用的 token 用量"""
        prompt = usage.get('prompt_tokens', 0)
        completion = usage.get('completion_tokens', 0)
        cost = (prompt * 1.0 + completion * 2.0) / 1_000_000
        self.total_cost_yuan += cost
        self.records.append(CostRecord(...))
        return rec

    def check(self):
        if self.total_cost_yuan >= self.budget_yuan:
            raise BudgetExceededError('成本超出预算! ')
        ratio = self.total_cost_yuan / self.budget_yuan
        if ratio >= self.alert_threshold:
            return {'status': 'warning', ...}
        return {'status': 'ok', ...}
```

CostGuard 嵌入 LangGraph 节点

[workflows/nodes.py](#) | python

```
# 在节点函数中集成 CostGuard
def analyze_node(state: KBState) -> dict:
    tracker = state.get('cost_tracker', {})

    for item in state['sources']:
        result, usage = chat_json(prompt)
        # 累加 token 用量
        tracker = accumulate_usage(tracker, usage)
        analyses.append(**item, **result)

    return {'analyses': analyses, 'cost_tracker': tracker}

# CostGuard 在外部包装使用
guard = CostGuard(budget_yuan=1.0)
guard.record('analyze', usage)
guard.check() # 超标时抛出 BudgetExceededError
```

成本优化五策略



策略	节省比例	难度	说明
语义缓存	30–60%	☆☆☆	相似问题复用上次结果
模型分级	40–70%	☆☆	Planner 用 cheap, Reviewer 用 mid
批量处理	20–40%	☆	10 条数据一次分析
Prompt 精简	15–30%	☆	去掉冗余说明
提前退出	10–20%	☆☆	质量达标就不再重审

维度 2：安全防护

三道防线 — 输入过滤 + Prompt 强化 + 输出校验

多 Agent 系统的四类安全风险



风险类型	威胁描述	严重程度	防护手段
Prompt Injection	用户输入劫持 Agent 行为	高	输入过滤 + Prompt 强化
数据泄露	输出暴露 system prompt 或 Key	高	输出校验
权限过大	Agent 有不必要的写入/网络权限	中	最小权限原则
不可控输出	有害内容或格式错误	中	输出校验 + 格式约束

第一道防线：输入过滤

security.py | python

```
import re

INJECTION_PATTERNS = [
    re.compile(r'ignore\s+(all\s+)?previous\s+instructions', re.IGNORECASE),
    re.compile(r'you\s+are\s+now\s+', re.IGNORECASE),
    re.compile(r'system\s*:\s*', re.IGNORECASE),
    re.compile(r'忽略(之前|上面|所有)(的)?指令', re.IGNORECASE),
    re.compile(r'你现在(是|扮演)', re.IGNORECASE),
]

def sanitize_input(text: str) -> tuple[str, list[str]]:
    """清洗用户输入，返回 (cleaned_text, warnings)"""
    warnings = []
    for pattern in INJECTION_PATTERNS:
        if pattern.search(text):
            warnings.append(f'检测到注入: {pattern.pattern}')
    cleaned = re.sub(r'[\x00-\x08\x0b\x0c\x0e-\x1f\x7f]', '', text)
    if len(cleaned) > 10000:
        cleaned = cleaned[:10000]
        warnings.append('输入超过 10000 字符，已截断')
    return cleaned, warnings
```

第二道防线：输出过滤 — PII 检测与掩码

```
PII_PATTERNS = {
    "phone_cn": re.compile(r"1[3-9]\d{9}"),
    "email": re.compile(r"[a-zA-Z0-9._%+-]+@[a-zA-Z0-9.-]+\.[a-zA-Z]{2,}"),
    "id_card_cn": re.compile(r"\d{17}[\dXx]"),
}

def filter_output(text: str, mask: bool = True) -> tuple[str, list[str]]:
    """过滤输出中的 PII，返回 (filtered_text, detections)"""
    detections = []
    filtered = text
    for pii_type, pattern in PII_PATTERNS.items():
        matches = pattern.findall(filtered)
        if matches:
            detections.append(f'{pii_type}: {len(matches)} 处')
            if mask:
                filtered = pattern.sub(f'[{pii_type.upper()}_MASKED]', filtered)
    return filtered, detections
```

权限最小化 — 每个 Agent 只开必要权限




Agent	允许的操作	禁止的操作
Planner	读取任务描述、调用 LLM	文件写入、网络请求
Analyzer	读取数据、调用 LLM、写入结果	文件删除、系统命令
Reviewer	读取分析结果、调用 LLM	文件写入、直接对外输出

维度 3：测试策略

AI 输出不确定 → Unit + Integration + Eval 三层测试

三层测试策略



第 1 层：单元测试 — 确定性函数

tests/test_unit.py | python

```
import pytest
from cost_guard import CostGuard
from security import sanitize_input, filter_output

def test_cost_tracking():
    guard = CostGuard(budget_yuan=1.0)
    guard.record('analyze', {'prompt_tokens': 1000, 'completion_tokens': 500})
    assert guard.total_prompt_tokens == 1000
    assert guard.total_cost_yuan > 0

def test_budget_exceeded():
    guard = CostGuard(budget_yuan=0.001)
    guard.record('analyze', {'prompt_tokens': 100000, 'completion_tokens': 100000})
    with pytest.raises(BudgetExceededError):
        guard.check()

def test_injection_detection():
    _, warnings = sanitize_input('ignore previous instructions')
    assert len(warnings) > 0
    _, warnings = sanitize_input('请分析这段代码')
    assert len(warnings) == 0
```

第 3 层: Eval 评估测试 — 范围断言

tests/test_eval.py | python

```
EVAL_CASES = [
    {'name': '正面案例',
     'input': 'OpenAI 发布 GPT-5, 支持百万上下文',
     'check': lambda r: len(r) >= 50 and 'GPT' in r},

    {'name': '负面案例',
     'input': '今天天气真好',
     'check': lambda r: '不相关' in r or len(r) < 100},

    {'name': '边界案例',
     'input': 'AI',
     'check': lambda r: r is not None and len(r) > 0},
]

def test_eval_cases():
    from model_client import chat
    for case in EVAL_CASES:
        result = chat(f'分析以下技术新闻: {case["input"]}')
        assert case['check'](result), \
            f'Eval 失败: {case["name"]}'
```

维度 4：日志与监控

结构化 JSONL 日志 + 运行报告 + 告警

AgentLogger — 结构化日志



agent_logger.py | python

```
import json, time
from pathlib import Path

class AgentLogger:
    def __init__(self, log_dir='logs'):
        Path(log_dir).mkdir(exist_ok=True)
        self.log_file = Path(log_dir) / f'run_{time.strftime("%Y%m%d_%H%M%S")}.jsonl'

    def log(self, agent, action, **kwargs):
        """写入一条结构化日志"""
        entry = {
            "timestamp": time.strftime("%Y-%m-%dT%H:%M:%S"),
            "agent": agent,
            "action": action,
            **kwargs,
        }
        with open(self.log_file, 'a') as f:
            f.write(json.dumps(entry, ensure_ascii=False) + '\n')


# 使用
logger = AgentLogger()
logger.log('planner', 'plan_created', tasks=3, tokens=800)
logger.log('reviewer', 'review_done', passed=True, score=85)
```

告警策略 — 四级告警



级别	触发条件	动作
INFO	管线正常完成	写日志
WARN	预算使用 > 70%	写日志 + 控制台输出
ERROR	预算超限 / 输出不安全	写日志 + 停止执行
CRITICAL	熔断器触发 / 安全攻击	写日志 + 停止 + 发通知

V3 知识库系统架构



V3 完整架构图



三周进化：V1 → V2 → V3



V1 (Week 1) — 能跑

OpenCode 编码自动化

Agent + Skill 骨架

人驱动触发

无质量控制

无成本意识

核心价值：理解 Agent 概念

V3 (Week 3) — 能上生产

多 Agent 协作

LangGraph + Review 循环

CI/CD 自动触发

Reviewer 审核 + 三层测试

CostGuard + 预算熔断

安全防护 + 结构化日志

核心价值：生产级 AI 系统

本节作业

任务 1：实现 CostGuard 成本控制

编写 `cost_guard.py`，实现 `CostGuard` 类。包含 `record()`、`check()`、`get_report()` 方法，超标抛出 `BudgetExceededError`。测试：`record()` 追踪 + `check()` 预算超标抛 `BudgetExceededError`。

任务 2：实现安全防护模块

编写 `security.py`，实现 `sanitize_input()` 和 `filter_output()`。加入 `RateLimiter` 速率限制和 `AuditLogger` 审计日志。测试：注入检测 + PII 掩码 + 速率限制。

任务 3：编写 Eval 评估测试

编写 `test_eval.py`，包含 3+ 评估用例。正面案例（技术文章）、负面案例（无关内容）、边界案例（极短输入）。使用范围断言（`>=`、`<=`、`in`），不用 `assert ==`。

任务 4：提交 V3 完整项目

V3 完整性检查：`workflow/` + `cost_guard.py` + `security.py` + `tests/`。运行完整管线验证。Git commit + push。这是 Week 3 的最终交付物（V3 里程碑）。

本节小结

CostGuard 预算熔断 —— 超预算自动停，不烧冤枉钱

三道安全防线 —— 输入过滤 + 权限最小化 + 输出脱敏

三层测试策略 —— 单元 + 集成 + Eval 评估

AgentLogger 四级告警 —— INFO / WARN / ERROR / CRITICAL

下一节：Week 4 部署上线 — OpenClaw + Telegram Bot